

综合分析城市居民身体健康的影响因素

林淑琪

摘要

随着时代和生活方式的变化，慢性病对我国居民健康的影响日益严重。人体健康状况与年龄、生活习惯等紧密联系。本文基于调查问卷数据，综合分析居民生活中的问题，并探讨这些问题与生活习惯之间的关联。根据研究结果，将提出合理建议，以帮助居民改善生活方式，降低慢性病的发病率，提高整体健康水平。希望此研究能为居民的健康管理提供有益的参考。

关键词：居民健康状况；主成分分析；相关性分析；Logistic 回归分析；K-均值聚类分析

引言

身体健康作为人类生活中至关重要的一部分，对个人的生活质量、幸福感和社会功能都具有深远的影响。然而随着时代的变迁，以心脑血管疾病、糖尿病、恶性肿瘤以及慢性阻塞性肺病为代表的慢性非传染性疾病（以下简称慢性病）已经成为影响我国居民身体健康的重要问题。又随着人们生活方式的改变，慢性病的患病率持续攀升。众所周知，健康状况与年龄、饮食习惯、身体活动情况、职业等都有密切的关系。如何通过合理地安排膳食、适量的身体运动、践行健康的生活方式，从而达到促进身体健康的目的，这是全社会普遍关注的问题。

本文将参考某市卫生健康研究部门对部分居民所做的“慢性非传染性疾病及其相关影响因素流行病学”调查问卷表（附件 2），相应的调查数据结果（附件 1），中国营养学会最新修订的《中国居民膳食指南》中为平衡居民膳食提出的八条准则（附件 3）等信息数据，分析居民生活中习惯的合理性、存在的问题，影响居民身体健康的因素，及其习惯间的相关性，并给出合理建议。

一、居民饮食习惯的合理性和主要存在问题

通过参考附件 3 中所给中国营养学会最新修订的《中国居民膳食指南》中为平衡居民膳食提出的八条准则，首先制定出一个合理的评价指标，就调查表第四部分-饮食情况，来分析居民饮食习惯的合理性。

1.1 制定评价指标

首先，需要制定一个评价指标来衡量饮食习惯的合理性。本文设置一个从 0 到 1 的分数，其中 1 代表完全符合膳食指南的建议，0 代表完全不符合。

1.1.1 设立基准

根据《中国居民膳食指南》的建议为每种食物或食物类别设定推荐摄入量。例如，每日推荐摄入全谷物和豆类 50~150g，新鲜蔬菜不少于 300g，食盐不超过 5g 等等。

1.1.2 定义得分机制

（1）定量评分：

对每种食物或食物种类，根据实际摄入量和推荐摄入量之间的比例分配评分，具体为：

实际摄入量在推荐范围内：得 1 分；

实际摄入量低于或高于推荐范围（ $\pm 20\%$ ）：得 0.8 分；

实际摄入量低于或高于推荐范围（ $\pm 50\%$ ）：得 0.5 分；
 实际摄入量低于或高于推荐范围（ $\pm 70\%$ ）：得 0.3 分；
 实际摄入量远低于或高于推荐范围（ $> \pm 70\%$ ）：得 0 分。

(2) 定性评分

对于一些不容易量化的推荐摄入标准，如“少吃高盐、高糖和油炸食品”，可使用定性评分，具体为：

不吃或很少吃高盐、高糖和油炸食品：得 1 分；
 偶尔吃高盐、高糖和油炸食品：得 0.8 分；
 较少吃高盐、高糖和油炸食品：得 0.5 分；
 较常吃高盐、高糖和油炸食品：得 0.3 分；
 常吃高盐、高糖和油炸食品：得 0 分。

1.1.3 综合得分

将所有食物或食物种类的得分通过主成分分析计算，得到一个区间 $[0, 1]$ 的综合得分，其中 1 代表完全符合膳食指南的建议，0 代表完全不符合。

1.1.4 设定界值

设定评判饮食习惯合理性的分数界值，具体为：

综合得分为 $0.8 \sim 1$ 分：饮食习惯合理；
 综合得分为 $0.5 \sim 0.8$ 分：饮食习惯较合理；
 综合得分为 $0 \sim 0.5$ 分：饮食习惯不合理。

1.2 建立模型

1.2.1 计算得分

根据定量和定性评分准则，对每种食物计算得分，该得分反映实际摄入量在推荐范围的比重。例如若实际摄入量在推荐范围的 80% 内，得 0.8 分。

得分的计算采用以下逻辑：

若 $r_i = [a, b]$

$$\begin{aligned} & \text{if } a_i \in 0.3r_i, s_i = 0.3 \\ & \text{else if } a_i \in 0.5r_i \cup [0.3b, 0.5a], s_i = 0.5 \\ & \text{else if } a_i \in 0.8r_i \cup [0.5b, 0.8a] \cup [0.8b, a], s_i = 0.8 \\ & \text{else if } a_i \in r_i \cup [0.8b, a], s_i = 1 \\ & \text{else if } a_i \in 1.2r_i \cup [b, 1.2a], s_i = 0.8 \\ & \text{else if } a_i \in 1.5r_i \cup [1.2b, 1.5a], s_i = 0.5 \\ & \text{else if } a_i \in 1.7r_i \cup [1.5b, 1.7a], s_i = 0.3 \\ & \text{else } s_i = 0 \end{aligned}$$

若 $r_i = [a, +\infty]$

$$\begin{aligned} & \text{if } a_i \in r_i, s_i = 1 \\ & \text{else if } a_i \geq 0.8a, s_i = 0.8 \\ & \text{else if } a_i \geq 0.5a, s_i = 0.5 \\ & \text{else if } a_i \geq 0.3a, s_i = 0.3 \\ & \text{else } s_i = 0 \end{aligned}$$

若 $r_i = [0, b]$

$$\begin{aligned} & \text{if } a_i \in r_i, s_i = 1 \\ & \text{else if } a_i \in [b, 1.2a], s_i = 0.8 \\ & \text{else if } a_i \in [1.2b, 1.5a], s_i = 0.5 \\ & \text{else if } a_i \in [1.5b, 1.7a], s_i = 0.3 \end{aligned}$$

$$\text{else } , s_i = 0$$

其中, s_i 为第 i 种食物的得分; a_i 为第 i 种食物的实际摄入量; r_i 为第 i 种食物的推荐摄入范围, $cr_i = [ca, cb]$, 如 $0.3r_i = [0.3a, 0.3b]$ 。

具体涉及评分的食物种类及评分详情见表 1。

表 1 评分准则

种类得分 s_i	1 分	0.8 分	0.5 分	0.3 分	0 分
谷物杂粮 50~150g/天	120~150g	75~120g/ 150~180g	45~75g/ 180~225g	15~45g/ 225~255g	<15g/ >255g
畜禽肉 300~500g/周	400~500g	250~400g/ 500~600g	150~250g/ 600~750g	90~150g/ 750~850g	<90g/ >850g
奶制品 ≥500g/天	≥500g	400~500g	250~400g	150~250g	<150g
蛋类 300~350g/周	300~350g	175~300g/ 350~420g	105~175g/ 420~525g	90~105g/ 525~595g	<90g/ >595g
新鲜蔬菜 ≥300g/天	≥300g	240~300g	150~240g	90~150g	<90g
新鲜水果 200~350g/天	280~350g	175~280g	105~175g	60~105g	<60g
烹调油 25~30g/天	25~30g	15~25g	9~15g	7.5~9g	<7.5g/ >30g
食盐 ≤5g/天	≤5g	5~6g	6~7.5g	7.5~8.5g	>8.5g
少吃油炸面 食/月	0~3 次	3~5 次	5~7 次	7~9 次	>9 次

选取附件 1 中所需数据后用公式计算, 能够得出每个居民每种食物相应得分。

1.2.2 主成分分析计算总得分

为了能客观、准确、合理地评估居民的饮食习惯, 本文选取了 9 个摄入量得分指标, 建立相应的统计评价指标体系, 具体包括: (1) s_1 : 谷物杂粮得分; (2) s_2 : 畜禽肉得分; (3) s_3 : 奶制品得分; (4) s_4 : 蛋类得分; (5) s_5 : 新鲜蔬菜得分; (6) s_6 : 新鲜水果得分; (7) s_7 : 烹调油得分; (8) s_8 : 食盐得分; (9) s_9 : 油炸面食得分。

采用 SPSS27.0 软件中的主成分分析法分析每个居民的饮食习惯合理性, 从而为评估整体饮食习惯合理性提供参考。主成分分析法的原理是利用降维思想, 通过研究指标体系的内在结构关系, 把多指标转化成少数几个相互独立而且包含原有指标大部分信息的综合指标的多元统计方法。优点为确定的权数是基于数据

分析得到的指标间的内在结构关系,而不受主观因素的影响,且得到的综合指标(主成分)之间彼此独立,能够减少信息交叉,使分析评价结果具有客观性和准确性^[1]。

选取所需数据后获得数据文件,在 SPSS27.0 中打开,选择 Analyze(分析)——Dimension Reduction(降维)——Factor(因子);将 $s_1 - s_9$ 添加到 Variables(变量)列表中,进行主成分分析,得到了方差贡献分析表(总方差解释)(表 2)、主成分载荷矩阵(成分得分系数矩阵)(表 3)。

表 2 方差贡献分析表(总方差解释)

成分	初始特征值			旋转载荷平方和		
	特征值	方差 贡献率/%	累计 贡献率/%	特征值	方差 贡献率/%	累计 贡献率/%
1	1.432	15.909	15.909	1.247	13.858	13.858
2	1.329	14.767	30.677	1.227	13.632	27.490
3	1.134	12.595	43.272	1.171	13.012	40.502
4	1.050	11.662	54.934	1.064	11.821	52.322
5	0.935	10.387	65.320	1.012	11.248	63.571
6	0.843	9.369	74.689	1.001	11.119	74.689
7	0.811	9.012	83.701			
8	0.767	8.527	92.228			
9	0.699	7.772	100.000			

(提取方法:主成分分析法)

表 3 主成分载荷矩阵(成分得分系数矩阵)

	主成分					
	1	2	3	4	5	6
s_1	-0.059	0.116	0.634	0.075	-0.206	0.004
s_2	0.022	-0.044	0.675	-0.134	0.244	-0.049
s_3	0.002	-0.110	-0.051	0.901	-0.032	0.022
s_4	-0.029	0.002	0.030	-0.029	0.948	0.026
s_5	0.041	0.734	-0.027	-0.282	-0.001	-0.008
s_6	-0.043	0.532	0.108	0.261	-0.008	-0.030
s_7	0.633	0.022	-0.018	0.016	-0.088	-0.013
s_8	0.633	-0.014	-0.030	-0.042	0.042	0.014
s_9	0.001	-0.024	-0.025	0.020	0.027	1.002

(提取方法:主成分分析法)

旋转方法:凯撒正态化最大方差法
组件得分)

从表 2 中可得初值特征值,表示在未旋转情况下,每个主成分解释的总方差。特征值越大,表示该主成分解释的方差越多。为确保提取的主成分能解释大部分的方差,在此选取累计方差贡献率达到 70%的成分,也就是表 2 中的成分 1-6,再进行因子旋转。前 6 个成分旋转前后的累计贡献率为 74.689%,解释了数据集中大部分的总方差,是主要的解释变量,故选取为第一主成分、第二主成分、第

三主成分、第四主成分、第五主成分和第六主成分。

表 3 成分得分系数矩阵表示了每个原始变量在每个主成分上的线性组合系数。通过这些系数，可以计算每个样本在各主成分上的得分。通过如下公式计算主成分的表达式：

$$F_j = \sum_{i=1}^9 c_{ij}s_i, j = 1, 2, \dots, 6$$

其中， F_j 为第 j 个主成分， c_{ij} 为主成分载荷矩阵中的载荷量， s_i 为成分。

由以下公式可进一步得到每个居民饮食习惯合理性的主成分得分(部分居民主成分得分见表 4)：

$$S = \sum_{j=1}^6 b_j F_j$$

其中 b_j 为第 j 个主成分的旋转后方差贡献率。

表 4 部分居民饮食习惯合理性主成分得分

	第一主 成分得 分 F_1	第二主 成分得 分 F_2	第三主 成分得 分 F_3	第四主 成分得 分 F_4	第五主 成分得 分 F_5	第六主 成分得 分 F_6	综合得分 S
居民 1	0.4715	1.2802	0.9802	-0.1623	0.4152	0.9372	0.499124439
居民 2	0.1297	0.8656	1.1107	0.4444	0.5683	0.9504	0.502626586
居民 3	-0.0249	0.2548	0.22	-0.0808	0.2081	1.0094	0.186001
...							

通过对全体居民的综合得分做描述性统计，分析结果包括：全体居民综合得分描述(表 5)、茎叶图(略)、全体居民饮食习惯综合得分箱线图(图 1)。

表 5 全体居民饮食习惯综合得分描述

S	统计
平均值	0.35985277593
中位数	0.35719254300
方差	0.009
最大值	0.000000000
最小值	0.689399760




图 1 全体居民饮食习惯综合得分箱线图

通过观察图表可得知，居民整体综合得分呈现出低分区间且分布极为集中的趋势。这意味着大多数居民的综合得分都偏低，并且在一个较窄的得分范围内集中分布。根据评判界值的标准，这种情况表明居民的整体饮食习惯可能存在不合理的情况。

1.3 结果分析

在计算每种食物得分 s_i 的平均值后，了解到居民在奶制品得分上极低，仅有 0.097，而在新鲜蔬菜和少吃油炸面食上表现最好，平均得分分别为 0.720 和 0.927，而其余种类的得分情况相差不大且基本位于 $[0.3, 0.4]$ 区间。

这些数字特征与上述综合得分暗示了居民在饮食方面存在着一些共同的问题或者趋势，主要包括饮食结构单一、营养摄入不足或者营养失衡等。这种情况需要引起我们的关注，因为不合理的饮食习惯可能会增加患慢性疾病的风险，影响健康水平和生活质量。因此，我们需要采取有效的措施，促进居民的健康饮食意识，推动形成健康、多样化的饮食习惯，以提高整体健康水平和生活质量。

二、影响居民生活习惯和饮食习惯的因素

基于上文对居民饮食习惯合理性和主要存在问题的分析讨论,此部分针对一些主观上的可能致因成分,进行与饮食习惯和生活习惯的相关性分析,从而能相对客观地分析影响因素。

2.1 数据选取与预处理

饮食习惯数据选取上一部分结果中的综合得分 S ；生活习惯选取调查表中第二部分吸烟情况（是否吸烟）、第三部分饮酒情况（饮酒年数）和第五部分身体活动情况（是否参加体育锻炼）；影响因素选取第一部分基本情况（出生年、性别、婚姻状况、文化程度）。

将选取数据导入 Excel 后, 筛查并将缺失值或异常值删除。

2.2 描述性统计

首先,对以上选取数据进行数据分析,求出平均值、最大值和最小值。见表6。

表6 影响因素及结果描述

	平均值	最大值	最小值
出生年	1970.51	1994	1922
性别	1.17	2	1
婚姻状况	1.94	5	1
文化程度	3.98	6	1
是否吸烟	2.03	3	1
饮酒年数	17.15	63	1
是否参加体育锻炼	1.98	4	1
饮食习惯	0.344	0.689	0.00

其中部分数字代表:性别:1-男,2-女;婚姻状况:1-未婚,2-已婚,3-再婚,4-离婚,5-丧偶;文化程度:1-文盲,2-小学,3-初中,4-高中/中专,5-大本/大专,6-研究生及以上;是否吸烟:1-是,2-过去吸,现在已戒烟,3-不吸;饮酒年数:99-记不清;是否参加体育锻炼:1-不参加,2-1~2天/周,3-3~5天/周,4->5天/周。其中若饮酒年数数据显示99,为便于统计分析,作2022-出生年-20处理。

2.3 相关性分析

对生活习惯、饮食习惯与影响因素之间进行相关性分析。

采用SPSS27.0软件中的相关性分析来分析生活习惯饮食习惯与可能影响因素的相关性,从而为了解和调整生活、饮食习惯提供参考。“一般来说,相关系数是描述两个变量之间关系程度的一个单一数字。最常用的相关系数是皮尔逊相关系数 r ,它测量两个变量在区间或比率尺度上的线性关系程度。 r 的值范围从-1到+1。+1的值表示完全正线性关系,-1的值表示完全负线性关系,0的值表示没有线性关系。^[2]”“重要的是要记住,相关性不意味着因果关系。即使两个变量高度相关,也不意味着一个变量导致了另一个变量。^[3]”

在SPSS27.0中打开数据文件,选择Analyze(分析)——Correlate(相关)——Bivariate(双变量);将所有变量添加到Variables(变量)列表中,选中“Pearson”相关系数及“Flag significant correlations(标记显著性相关性)”进行相关性分析,得到了相关矩阵,选取需要进行分析的数据,得到表7。

表7 部分相关矩阵

		出生年	性别	婚姻状况	文化程度
生活习惯	是否吸烟	0.025*	0.567**	0.016	-0.017
	饮酒年数	-0.573**	-0.023	0.204**	-0.176**
	是否参加体育锻炼	-0.190**	-0.042**	-0.005	0.049**
	饮食习惯	-0.001	0.236**	0.040**	0.178**

(**, 在0.01级别(双尾),相关性显著。

*. 在 0.05 级别（双尾），相关性显著。）

是否抽烟与出生年、性别、婚姻状况呈正相关，与文化程度呈负相关，但与后二者间的相关性不显著，与出生年在 0.05 级别上显著，与性别在 0.01 级别上显著分别说明出生年略晚的人吸烟的可能性略高以及男性吸烟的可能性显著高于女性。在饮酒习惯方面，出生年晚、文化程度高和未婚者的饮酒年数相对短，与性别相关性不显著。体育锻炼方面，出生年早、文化程度高和女性的参加体育锻炼的可能性相对大，与婚姻状况相关性小。综合说明在这三个维度上，生活习惯与出生年的相关性最显著，在一定程度上反映了现代年轻人在种种外因与内因的影响下，形成了较差的生活习惯，且在男性和低文化程度者身上体现更为明显。

而饮食综合得分与出生年相关性不显著，与女性、已婚者和文化程度高的人相关性相对高，说明其饮食习惯相对更好。

三、影响常见慢性病致病的因素及相关性

在初步了解与生活、饮食习惯相关性较大的因素后，为进一步探索慢性病与人们生活方式间的关联，本文将深入分析常见慢性病如高血压等与身体指标、职业、饮酒、饮食习惯、运动等因素的关系以及相关程度，进而寻找可能存于日常生活中的慢性病诱因，作为人们提前预防或改善的参考依据。

3.1 数据预处理

此部分选择对高血压进行分析。在筛选查看其相关调查数据后可知未被社区或以上医院的医生诊断患有高血压的人群占总体受调查人群的 84.1%，占压倒性多数，体现类别不平衡，这会导致对患高血压类的识别能力较差，从而影响模型性能和分析结果，故采用欠采样(Under-sampling)的数据平衡处理，减少多数类即未患病人群的样本量，使两类样本数量接近，本文选择减少多数类个数至与少数类个数几乎相等。

参与分析的数据包括：高血压(二元变量)、职业、饮酒年数、盐、酱油、体育锻炼强度、平均每天体育锻炼时间、BMI(由表中体重(kg)/身高(m)²得到)。将高血压由 1-是，2-否改为 1-是，0-否；饮酒年数、体育锻炼强度和平均每天体育锻炼时间数据中空白处填充为 0。

且为避免量纲对模型回归和数据分析的影响，预先将所有变量值标准化。

3.2 模型建立

3.2.1 回归分析模型选择

由于高血压数据为二分类变量，即只有两个可能的类别，此处为是/否，不适用于线性回归模型，故采用二元 logistic 模型进行建模分析。

将高血压设为因变量作为模型中的被解释变量，其余变量设为协变量作为解释变量（“协变量数值类型一般为数值型。如果解释变量为分类变量或定性变量，则可以用虚拟变量(哑变量)表示。”^[4]）

3.2.2 二元 logistic 模型回归分析

使用 logistic 回归模型分析相关性的主要原理是根据回归结果数据研究自变量对因变量的影响，如：回归系数表示自变量对因变量对数几率的影响，正值表示正相关，负值表示负相关；显著性水平(p 值)用于检验自变量对因变量影响的显著性，通常 p 值<0.05 表示该自变量对因变量有显著影响；对回归系数取指数可以得到 Odds Ratio，表示自变量变化一个单位时，事件发生几率相对于不发生几率的变化，OR>1 表示正相关，OR<1 表示负相关。

选取所需数据并预处理后获得数据文件，在 SPSS27.0 中打开，选择

Analyze(分析)——Regression(回归)——Binary Logistic(二元 Logistic)；将高血压选入 Dependent(因变量)列表框中，将其余变量选入 Covariates(协变量)列表框中，选中 Options(选项)——Classification plots(分类图)，进行 Logistic 回归，得到了模型系数的综合检验(表 8)、方程中的变量(标准化后)(表 9)。

表 8 模型系数的综合检验

		卡方	自由度	显著性
步骤 1	步骤	224.461	7	<0.001
	块	224.461	7	<0.001
	模型	224.461	7	<0.001

表 9 方程中的变量(标准化后)

		B	标准误差	瓦尔德	自由度	显著性	Exp(B)
步骤 1 ^a	职业	0.197	0.063	9.791	1	0.002	1.218
	饮酒年数	0.086	0.061	1.947	1	0.163	1.089
	盐	0.050	0.064	0.612	1	0.434	1.052
	酱油	0.048	0.063	0.591	1	0.442	1.049
	体育锻炼强度	0.051	0.086	0.351	1	0.553	1.052
	平均每天体育锻炼时间	0.193	0.087	4.899	1	0.027	1.213
	BMI	0.914	0.073	154.891	1	<0.001	2.495
	常量	0.009	0.062	0.023	1	0.880	1.009

其中部分标准化前变量的数据代表：职业：1-工人，2-农民，3-军人，4-行政干部，5-科技人员，6-医务人员，7-教师，8-金融财务，9-商业服务人员，10-家庭妇女，11-离、退休人员，12-待业，13-学生；体育锻炼强度：0-不锻炼，1-中等强度体育锻炼，如快走、慢跑、慢速游泳、太极拳、木兰拳、乒乓球、扇子舞、交谊舞、秧歌等，2-大强度体育锻炼，如中速跑步、中速游泳、足球、篮球、羽毛球等。

从表 8 中可知“步骤 1”和基于该模块建立模型的卡方值为 224.461，显著性<0.001，可见模型十分显著，因此可以从该模型的回归结果中获取有效信息。

由表 9 得各自变量的回归系数 B 均为正数，说明各自变量的增加与高血压的患病可能性增加正相关，其中 BMI 的系数值最高且远高于其他变量的系数，职业和平均每天锻炼时间次之且相近，说明三者对高血压患病可能性的有很大的影响幅度。且三者显著性均<0.05，说明对高血压的影响非常显著，其中 BMI 的影响极其显著，每增加一个标准差，高血压患病的几率增加 2.495 倍。而其余变量对高血压的影响小且显著性低。

由 Logistic 模型的数学表达式：

$$\ln \frac{p}{1-p} = \alpha + X\beta + \varepsilon$$

其中 p 为事件发生概率； α 为模型的截距项； β 为待估计参数； X 为解释变量； ε 为误差项^[4]。可以得知本模型高血压患病概率与影响因素之间的关系，即：

$$\ln \frac{p}{1-p} = 0.009 + 0.197x_1 + 0.086x_2 + 0.05x_3 + 0.048x_4 + 0.051x_5 + 0.193x_6 + 0.914x_7$$

从此样本中了解到，平均每天体育锻炼时间与高血压呈正相关，即锻炼时间越长患病概率越高的结果似乎有违常识，为使结果更加直观和可视化，采用绘制概率曲线的方法对其和 BMI 指标做进一步分析。如图 2、图 3。




图2BMI 与高血压概率曲线




图3 平均每天体育锻炼时间与高血压概率曲线

图中曲线表示了变量和高血压概率之间的关系，灰色阴影区域表示拟合曲线的置信区间。

由图 2 可以看出随着 BMI 的增加，高血压的概率也随之增加，而随着 BMI 进一步增加，高血压的概率略有下降，但仍维持在较高水平。红色数据点(无高血压)大多分布在较低的 BMI 区域，青色点(有高血压)大多在较高 BMI 区域。在 BMI 值较高区域，灰色阴影区域变宽，即置信区域变宽，表明在这些区域模型的预测不确定性较大。

由图 3 的曲线走向可以看出平均每天体育锻炼时间和高血压概率呈正相关，然而在图的右半部分也就是较高的平均锻炼时间区间，数据点明显稀疏，且灰色区域相较于图 2 明显变宽且随着平均锻炼时间的增多迅速变宽，这说明了模型在这些区域的预测不够可靠、不稳定且不确定性大，缺乏足够的样本数据来支撑模型的拟合；再加上可能存在的数据选择偏倚、锻炼频率和其他潜在因素的影响，从而可能反映出一个反直觉的现象，进一步的偏相关分析或许能优化数据结果。但超出正常范围的高强度锻炼或不规律锻炼确实可能对健康有负面影响，从而增加高血压的概率。

3.2.3 结果分析

在此部分研究分析的影响因素中，BMI、职业和平均每天体育锻炼时间对高血压的影响显著，但由于样本的特殊性，可能无法得到普适结果，但仍具有一定参考性，居民可对照以上因素对自身数据指标进行比照考查，合理调整体育锻炼

时间、强度和饮食习惯等，劳逸结合。

四、合理分类与建议

对数据进行合理选取并作标准化处理，依据附件 1 中居民的具体情况，使用聚类分析的方法将居民合理分为 7 大类，并依据聚类结果，针对各类人群提出有利于身体健康的膳食、运动等方面的合理建议。

4.1 数据预处理

此部分选取饮酒情况、体育锻炼、性别、职业、饮食习惯作为分类变量，其中饮酒情况为调查表中居民对所有酒类在一周内的饮用量相加；体育锻炼为体育锻炼强度与平均每天体育锻炼时间相乘，将二者缺失数据填充为 0，其余变量的缺失数据作删除样本处理。最后对饮酒情况、体育锻炼、饮食习惯作标准化处理。

4.2 模型建立

4.2.1K-均值聚类分析

在 K-均值方法中，一组观测数据根据某些准则被分成 K 个簇。其基本思想是在变量空间中选择 K 个点作为簇中心。然后，将每个观测数据分配给离它最近的簇中心所代表的簇，并且每个簇中心点被重新计算为其分配到的观测数据的质心。^[5]本部分将以此方法对居民进行分类。

选取所需数据并预处理后获得数据文件，在 SPSS27.0 中打开，选择 Analyze(分析)——Classify(分类)——K-Means Cluster(K-均值聚类)；将上述变量选入 Variables(变量)列表框中，设置聚类数目即 K 值为 7，进行 K-均值聚类分析，得到了聚类分析结果(表 10)。

表 10 聚类分析结果

	1	2	3	4	5	6	7
性别	2	1	1	1	1	1	2
职业	12	5	5	10	2	1	9
饮酒	-0.1	10.462	-0.056	3.4475	4.3008	-0.065	-0.191
情况	6831	82	71	6	5	55	14
体育	0.23	-0.163	0.1539	0.0772	-0.058	-0.149	-0.139
锻炼	180	74	8	2	96	31	62
饮食	0.08	-0.129	0.0977	-0.331	-0.432	-0.253	0.0399
习惯	008	19	1	90	58	66	8

由此将居民分为 7 大类。

4.2.2 给出合理建议

聚类 1：女性占多数，主要为待业人员，饮酒习惯中性，有一定体育锻炼习惯，饮食习惯相对健康或均衡。建议此类人群继续维持该良好生活、饮食习惯，可关注职业健康。

聚类 2：男性占多数，主要为科技人员，饮酒习惯异常高，体育锻炼习惯较少，饮食习惯相对不健康或不均衡。此类人群生活、饮食习惯差，建议适当增加锻炼并优化饮食，注重饮食的质量。

聚类 3：男性占多数，主要为科技人员，饮酒习惯中性，有一定体育锻炼习惯，饮食习惯相对健康或均衡。建议此类人群继续维持该良好生活、饮食习惯。

聚类 4：男性占多数，主要为家庭主夫，饮酒习惯较高，体育锻炼习惯较少，饮食习惯相对不健康或不均衡。此类人群的饮酒习惯、锻炼情况和饮食情况一般，

建议增加锻炼时间，优化饮食，改进习惯，建议定期进行身体检查。

聚类 5：男性占多数，主要为农民，饮酒习惯较高，体育锻炼习惯较少，饮食习惯相对不健康或不均衡。此类人群生活、饮食习惯较差，建议适当增加锻炼并注重饮食的质量。

聚类 6：男性占多数，主要为工人，饮酒习惯中性，体育锻炼习惯较少，饮食习惯相对不健康或不均衡。此类人群在一定程度上由于工作性质，锻炼习惯和饮食习惯不健康，建议合理利用时间增加锻炼，增加蔬菜和水果的摄入量。

聚类 7：女性占多数，主要为商业服务人员，饮酒习惯中性，体育锻炼习惯较少，饮食习惯相对健康或均衡。建议增加锻炼并逐渐形成习惯，并优化饮食结构。

五、参考文献

- [1]潘安娥,杨青. 基于主成分分析的武汉市经济社会发展综合评价研究[J]. 中国软科学, 2005 (7): 118 - 121.
- [2]Cohen, J., Cohen, P., West, S. G., & Aiken, L. S. (2003). Applied Multiple Regression/Correlation Analysis for the Behavioral Sciences (3rd ed.). Routledge.
- [3]Mukaka, M. M. (2012). A guide to appropriate use of Correlation coefficient in medical research. Malawi Medical Journal, 24(3), 69-71.
- [4]杨维忠, 陈胜可, 刘荣. SPSS 统计分析从入门到精通 (第四版)[M]. BEIJING BOOK CO. INC., 2019.
- [5]Hartigan, J. A., & Wong, M. A. (1979). Algorithm AS 136: A K-means clustering algorithm. Journal of the Royal Statistical Society. Series C (Applied Statistics)

六、致谢

本论文使用了 ChatGPT(, <https://chatgpt.com/>) 和 kimi(, <https://kimi.moonshot.cn/>), 做了写作和代码指导

数据来源:

数据提供者: 本论文的数据来源于深圳市尚龙数学技术与交叉学科产业化研发中心发布的慢性病及相关因素的流调数据(附件 1)和流调调查表(附件 2)、中国营养学会发布的中国居民膳食指南平衡膳食八条准则(2022)(附件 3)

数据获取方法: 数据通过面向部分城市居民的问卷调查收集

数据类型:

数据类别: 本论文包含定性数据(性别: 男/女; 职业: 工人、农民等)和定量数据(饮酒年数: 年; 食用频率: 次等)

数据结构: 本论文的数据为截面数据, 记录了多个不同个体调查对象在较短时间内内的特征和关系

数据单位:

如: 性别: 无单位; 饮酒年数: 年; 平均每天体育锻炼时间: 分钟等